

Spark SQL优化作业

思考题：如何避免小文件问题

形成小文件的背景可能有：

Spark SQL在执行ETL (filter/shuffle) 后，很难评估待写出的数据量，再加上写出的数据大小会受到压缩算法和存储格式的影响，则有可能生成的数据文件很多，但每个文件都很小，也就是一组碎片化的文件。

文件数量主要是shuffle操作决定：

1. shuffle分区过多过碎，则会导致写入性能差且小文件数量多。
2. shuffle分区过少过大，写入并发度不够，影响任务执行效率。

碎片文件导致后续在读表查询时产生读性能问题，主要可能有：

1. 读操作时，文件listing操作非常耗时（需要寻找读入大量文件），造成磁盘和网络的IO影响；同时也对nameNode的内存造成压力。
2. spark SQL任务执行，会根据文件数量启动大量的map task，单个task虽然执行很快，但对调度系统yarn带来压力，整体耗时反而增大。
3. hdfs的存储时面临超出文件个数上限的潜在风险，这主要是底层操作系统Linux/Unix的文件系统决定的。

解决思路主要有以下几个方面：

1. SQL层面解决

1.1 设置参数调节并行度

通过set spark.sql.shuffle.partitions参数，比如从200调整至100来降低并行度，导致最终生成的文件数量减少。但坏处是执行耗时会增加，减少小文件的效果有，但不理想。

1.2 增加一个并行度=1的job，专门合并小文件。

先将数据写入一个临时分区，再通过 `set spark.sql.shuffle.partitions=1`，和类似如下SQL语句落盘最终数据文件

```
insert overwrite table targetTable  
select * from sourceTable group by *
```

`group by`在spark中属于宽依赖，所以会进行shuffle操作，如此将原先的多个小文件通过shuffle后合并成少量的大文件。

1.3 与2类似，通过SQL语句在写表操作时合并小文件

在查询任务完成后，通过 `distribute by rand()` 来触发shuffle操作重新分区。`rand()`函数会将数据随机分发，如此重新分区后，每个分区大小基本相等，文件大小也会尽量靠近 `block size` 的大小。

```
select * from table distribute by rand()
```

2. 实现一个自定义SQL语法进行文件合并的操作

主要功能：

- 2.1 能够指定表或分区的文件合并
- 2.2 对于分区表：如果指定分区则合并分区；如果没有指定分区，则递归所有分区进行合并
- 2.3 如果指定生成的文件数量，直接按文件数量合并

实现Compact table command

- 1. 在SqlBase.g4中添加自定义命令compact table。

```
| SHOW VERSION #showSparkAndJavaVersion
| COMPACT TABLE target=tableIdentifier partitionSpec?
  (INTO fileNum=INTEGER_VALUE identifier)? #compactTable
| unsupportedHiveNativeCommands .*? #failNativeCommand
;
```

2. 通过maven重新编译antlr4。

```
Downloaded from apache.snapshots: https://repository.apache.org/snapshots/org/apache/spark/spark-sketch\_2.12/3.3.0-SNAPSHOT/spark-sketch\_2.12-3.3.0-SNAPSHOT.jar
Downloaded from apache.snapshots: https://repository.apache.org/snapshots/org/apache/spark/spark-unsafe\_2.12/3.3.0-SNAPSHOT/spark-unsafe\_2.12-3.3.0-SNAPSHOT.jar
Downloaded from apache.snapshots: https://repository.apache.org/snapshots/org/apache/spark/spark-network-common\_2.12/3.3.0-SNAPSHOT/spark-network-common\_2.12-3.3.0-SNAPSHOT.jar
Downloaded from apache.snapshots: https://repository.apache.org/snapshots/org/apache/spark/spark-core\_2.12/3.3.0-SNAPSHOT/spark-core\_2.12-3.3.0-SNAPSHOT.jar
[INFO]
[INFO] --- antlr4-maven-plugin:4.8:antlr4 (default-cli) @ spark-catalyst-2.12 ---
[INFO] ANTLR 4: Processing source directory /Users/chenhao/github_code/spark/sql/catalyst/src/main/antlr4
[INFO] Processing grammar: org/apache/spark/sql/catalyst/parser/SqlBase.g4
[INFO] -----
[INFO] BUILD SUCCESS
[INFO] -----
[INFO] Total time: 06:30 min
[INFO] Finished at: 2021-09-20T22:15:09+08:00
[INFO] -----

Process finished with exit code 0
```

3. 在SparkSqlParser.scala中添加对应的visit方法visitCompactTable。

```
// visitCompactTable
override def visitCompactTable(ctx:
CompactTableContext): LogicalPlan = withOrigin(ctx) {
    // 获取目标表名
    // 获取指定分区
    // 获取指定的文件数, 若该参数为空调用operationNotAllowed方法给出告警信息
    val targetTable = visitTableIdentifier(ctx.target)
    val partSpecs = Option(ctx.partitionSpec).map
{ specCtx =>
    UnresolvedPartitionSpec(visitNonOptionalPartitionSpec(specCtx), None)
    }
    val fileNum = ctx.INTEGER_VALUE.getText.toInt
    if (fileNum.isEmpty) {
        operationNotAllowed("COMPACT TABLE must be specify
a int number for files", ctx)
    }
    CompactTableCommand(
        targetTable,
        partSpecs.toSeq,
```

```
        fileNum)
    }
```

4. 在org/apache/spark/sql/execution/command/下添加 CompactTableCommand.scala文件，实现CompactTableCommand方法。

4.1 getTableLocation函数：获取表底层文件的存储路径

4.2 moveFiles函数：用于移动指定目录下的文件

4.3 mergeFiles函数：用于通过coalesce函数实现小文件合并，同时通过两次调用moveFiles函数实现移动源文件到合并目录，和将合并后的新文件移动回源文件目录。

4.4 具体代码如下

```
package org.apache.spark.sql.execution.command

import java.net.URI
import java.util.Date

import org.apache.hadoop.fs.{FileSystem, Path}
import org.apache.log4j.Logger

import org.apache.spark.{SparkConf, SparkContext}
import org.apache.spark.sql.{Row, SaveMode, SparkSession,
SQLContext}
import org.apache.spark.sql.catalyst.TableIdentifier
import org.apache.spark.sql.catalyst.catalog.{CatalogTable,
CatalogTableType, InMemoryCatalog, SessionCatalog}
import org.apache.spark.sql.catalyst.parser.ParserInterface
import org.apache.spark.sql.internal.{SessionState, SharedState}

case class CompactTableCommand(
  targetTable: TableIdentifier,
  partSpecs: partitionSpec,
  fileNum: Int) extends LeafRunnableCommand {
```

```

    val sparkConf = new
SparkConf().setMaster("local[*]").setAppName("mergeFile")
    val sc = new SparkContext(sparkConf)
    val sqlContext = new HiveContext(sc)
    val fileSystem = FileSystem.get(sc.hadoopConfiguration)
    val logger = Logger.getLogger("org")

    override def run(sparkSession: SparkSession): Seq[Row] = {
        /*
        * * 合并步骤:
        * 1. 将小文件目录(srcDataPath)下的文件移动到临时目录/mergePath/{
mergeTime}/src
        * 2. 使用coalesce或者repartition, 传入分区数(默认500)。将数据写入
临时的数据目录(/mergePath/{mergeTime}/data)
        * 3. 将临时数据目录文件move到文件目录(srcDataPath)
        * 4. 删除临时目录(mergePath)
        * */
        val srcDataPath = getTableLocation(targetTable.toString,
sparkSession)
        val mergePath = "/Users/chenhao/github_code/spark/data/
mergeTmp"
        val mergeTime = new Date().getTime.toString
        val partitionSize = fileNum
        val result = mergeFiles(sqlContext, fileSystem,
            mergeTime, srcDataPath, mergePath, partitionSize)
        Seq(Row(logger.info("result: " + result)))
    }

    def mergeFiles(sqlContext: SQLContext, fileSystem: FileSystem,
mergeTime: String,
            srcDataPath: String, mergePath: String,
partitionSize: Int): String = {
        val mergeSrcPath = mergePath + "/" + mergeTime + "/src"
        val mergeDataPath = mergePath + "/" + mergeTime + "/data"
        var mergeInfo = "merge success"

        try {
            /*
            * 1.将需要合并的文件mv到临时目录
            * 2.将合并目录的src子目录下的文件合并后保存到合并目录mergeDataPath
            的data子目录下

```

```

    * 3.利用coalesce函数对数据文件重新分区（repartition函数应该也可以做到），即合并，并将文件保存至mergeDataPath目录下。
    * 3.将mergeDataPath的data目录下的文件移动到原目录
    * 4.删除合并目录src的子目录
    * */
    moveFiles(fileSystem, mergeTime, srcDataPath, mergeSrcPath,
true)
    val srcDF =
sqlContext.read.format("parquet").load(mergeSrcPath + "/")
    srcDF.coalesce(partitionSize).write.format("parquet")
    .mode(SaveMode.Overwrite).save(mergeDataPath)
    moveFiles(fileSystem, mergeTime, mergeDataPath,
srcDataPath, false)
    fileSystem.delete(new Path(mergePath + "/" + mergeTime),
true)

    } catch {
    case e: Exception => e.printStackTrace()
    mergeInfo = "merge failed"
    }
    mergeInfo
}

def moveFiles(fileSystem: FileSystem, mergeTime: String,
fromDir: String,
    destDir: String, ifTruncDestDir: Boolean): Unit =
{
    /*
    * 1.判断目标目录是否存在，不存在即建立
    * 2.是否清空目标目录下面的所有文件
    * 3.将srcDataPath目录下的除"_SUCCESS"外的文件逐个移动到
mergeSrcPath目录下
    * */

    val fromDirPath = new Path(fromDir)
    val destDirPath = new Path(destDir)

    if (!fileSystem.exists(new Path(destDir))) {
    fileSystem.mkdirs(destDirPath.getParent)
    }

    if (ifTruncDestDir) {

```

```

        fileSystem.globStatus(new Path(destDir + "/*") )
            .foreach(x => fileSystem.delete(x.getPath(), true))
    }

    var num = 0
    fileSystem.globStatus(new Path(fromDir + "/*")).foreach(x =>
    {
        val fromLocation = x.getPath().toString
        val fileName =
fromLocation.substring(fromLocation.lastIndexOf("/") + 1)
        val fromPath = new Path(fromLocation)

        if (fileName != "_SUCCESS") {
            var destLocation = fromLocation.replace(fromDir, destDir)
            val fileSuffix = if (fileName.contains("."))
                {fileName.substring(fileName.lastIndexOf("."))}
            else {""}
            val newFileName = mergeTime + "_" + num + fileSuffix
            destLocation = destLocation.substring(0,
destLocation.lastIndexOf("/") + 1) + newFileName
            num = num + 1

            val destPath = new Path(destLocation)

            if (!fileSystem.exists(destPath.getParent)) {
                fileSystem.mkdirs(destPath.getParent)
            }
            fileSystem.rename(fromPath, destPath) // hdfs dfs -mv
        }
    })
}

def getTableLocation(table: String, sparkSession:
SparkSession): String = {
    val sessionState: SessionState = sparkSession.sessionState
    val sharedState: SharedState = sparkSession.sharedState
    val catalog: SessionCatalog = sessionState.catalog
    val sqlParser: ParserInterface = sessionState.sqlParser
    val client = sharedState.externalCatalog match {
        case catalog: HiveExternalCatalog => catalog.client
        case _: InMemoryCatalog => throw new
IllegalArgumentException("In Memory catalog doesn't " +

```

```

        "support hive client API")
    }
    val idtfr = sqlParser.parseTableIdentifier(table)
    require(catalog.tableExists(idtfr), new
IllegalArgumentException(idtfr + " does not exist"))
    val rawTable =
client.getTable(idtfr.database.getOrElse("default"), idtfr.table)
    rawTable.location.toString
}
}

```

5. 编译暂未通过，调试中.....